

Статистика ФИВТ ПМИ

Прикладной поток

Лекция 11

5. Проверка статистических гипотез

5.4. p-value

Гипотезы (напоминание)

$X = (X_1, \dots, X_n)$ — выборка из неизвестного распределения $P \in \mathcal{P}$.

$H_0 : P \in \mathcal{P}_0$ — основная гипотеза;

$H_1 : P \in \mathcal{P}_1$ — альтернативная гипотеза.


$S \subset \mathcal{X}$ — критерий уровня значимости α для проверки H_0 vs. H_1 ,
если $P(X \in S) \leq \alpha, \forall P \in \mathcal{P}_0$.

Варианты ответа:

1. $X \in S \implies H_0$ отвергается \implies результат стат. значим;
2. $X \notin S \implies H_0$ **не отвергается** \implies результат не стат. значим

Гипотезы (напоминание)

Часто критерий имеет вид $S = \{T(x) \geq c\}$,
где $T(X)$ — статистика критерия.



H_0 отвергается $\iff T(X) \geq c_\alpha$

Значение t_1 более экстремально, чем t_2 , если $t_1 > t_2$.


Критерии (напоминание)

Часто критерий имеет вид $S = \{T(x) \geq c_\alpha\}$,
где $T(X)$ — статистика критерия.


α выбирается **ДО** эксперимента,

c_α вычисляется из условия $P_0(T(X) > c_\alpha) \leq \alpha$.


$$S = \{T(x) > c_\alpha\}$$



$$S = \{T(x) < c_\alpha\}$$



$$S = \{|T(x)| > c_\alpha\}$$



Замечание. Выбирать α после эксперимента неправильно.

Так можно подогнать результат под желаемый.

"Статистика может доказать что угодно, даже истину."

Пример (влияние нового препарата на выздоровление)

Испытуемые делятся случайно на две группы:

1. Исследуемая группа — принимает новый препарат;

$X = (X_1, \dots, X_n)$, $X_i \sim Bern(p_1)$ — результаты лечения.

2. Контрольная группа — принимает плацебо;

$Y = (Y_1, \dots, Y_m)$, $Y_i \sim Bern(p_2)$ — результаты лечения.

$H_0: p_1 = p_2$ — отсутствие эффекта

$H_1: p_1 > p_2$ — эффект присутствует


Пример (влияние нового препарата на выздоровление)

$$\hat{p}_1 = \bar{X} \stackrel{d}{\approx} \mathcal{N}\left(p_1, \frac{p_1(1-p_1)}{n}\right) \text{ и } \hat{p}_2 = \bar{Y} \stackrel{d}{\approx} \mathcal{N}\left(p_2, \frac{p_2(1-p_2)}{m}\right) - \text{ОМП}$$

При справедливости H_0 получаем

$$W(X, Y) = \frac{\hat{p}_1 - \hat{p}_2}{\hat{\sigma}} \stackrel{d}{\approx} \mathcal{N}(0, 1),$$

$$\text{где } \hat{\sigma} = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n} + \frac{\hat{p}_2(1-\hat{p}_2)}{m}}.$$



// Сходимость $W(X, Y) \xrightarrow{d} \mathcal{N}(0, 1)$ при $n, m \rightarrow +\infty$ можно доказать строго.

Критерий Вальда $S = \{W(x, y) > z_{1-\alpha}\}$.

$$\alpha = 0.05 \implies z_{1-\alpha} \approx 1.64, \quad S = \{W(x, y) > 1.64\}.$$

Дов. интервал для $p_1 - p_2$ равен $C = (\hat{p}_1 - \hat{p}_2 - z_{1-\alpha}\hat{\sigma}, 1)$.

H_0 отвергается $\iff 0 \notin C$



Пример (влияние нового препарата на выздоровление)

1. 1 группа: $n = 30$ человек, 27 выздоровело $\Rightarrow \hat{p}_1 = 0.9$

2 группа: $m = 30$ человек, 21 выздоровело $\Rightarrow \hat{p}_2 = 0.7$

$W(x, y) \approx 2 \Rightarrow H_0$ отвергается, результат стат. значим

дов. интервал $(0.036, 1) \leftarrow$ слабая уверенность в результате

2. 1 группа: $n = 30$ человек, 27 выздоровело $\Rightarrow \hat{p}_1 = 0.9$

2 группа: $m = 30$ человек, 15 выздоровело $\Rightarrow \hat{p}_2 = 0.5$

$W(x, y) \approx 3.76 \Rightarrow H_0$ отвергается, результат стат. значим

дов. интервал $(0.225, 1) \leftarrow$ хорошая уверенность в результате

3. 1 группа: $n = 30$ человек, 27 выздоровело $\Rightarrow \hat{p}_1 = 0.9$

2 группа: $m = 10$ человек, 7 выздоровело $\Rightarrow \hat{p}_2 = 0.7$

$W(x, y) \approx 1.54 \Rightarrow H_0$ не отвергается, результат стат. незнач.

дов. интервал $(-0.017, 1) \leftarrow$ нет результата

Материал на доске



p-value (достигаемый уровень значимости)

$$H_0 : P \in \mathcal{P}_0$$

x_1, \dots, x_n — реализация выборки

$T(x)$ — статистика критерия

$t = T(x_1, \dots, x_n)$ — реализация стат.

p-value — вероятность получить при справедливости H_0 такое значение статистики $t = T(x)$ или еще более экстремальное.

$$S = \{T(x) > c_\alpha\}$$




$$p(x) = P_0(T(X) \geq t),$$

$$S = \{T(x) < c_\alpha\}$$

$$p(x) = P_0(T(X) \leq t),$$

$$S = \{|T(x)| > c_\alpha\}$$

$$p(x) = P_0(T(X) \geq |t|) + P_0(T(X) \leq -|t|),$$




Замечание. Если распр. $T(X)$ при H_0 не одинаково, то нужно добавить $\sup_{P \in \mathcal{P}_0}$


В чем же разница? Графики одинаковые!!!

Еще раз посмотрим на них:





$$S = \{ T(x) > c_\alpha \}$$



$$S = \{ T(x) < c_\alpha \}$$




$$S = \{ |T(x)| > c_\alpha \}$$




Рассмотрим случай $S = \{T(x) > c_\alpha\}$

Критическое множество (слева) фиксировано.


Ниже p-value для различных реализаций.




$p\text{-value}(t) = 0.014$




$p\text{-value}(t) = 0.212$



$p\text{-value}(t) = 0.036$




$p\text{-value}(t) = 0.500$



$p\text{-value}(t) = 0.081$



$p\text{-value}(t) = 0.903$



Вывод:

H_0 отвергается $\iff p\text{-value} \leq \alpha$


В этом случае $p\text{-value}$ —
степень уверенности в отвержении H_0 .
(чем $p\text{-value}$ меньше, тем увереннее)

Пример (влияние нового препарата на выздоровление)


Критерий $S = \{W(x, y) > z_{1-\alpha}\}$, где $W(X, Y) \xrightarrow{d} \mathcal{N}(0, 1)$.

p-value: $p(w) = P(W(X, Y) > w) = \text{scipy.stats.norm.sf}(w)$.


$$w = W(x) = 2$$
$$p(w) = 0.0228$$



$$w = W(x) = 3.76$$
$$p(w) = 0.00008$$



$$w = W(x) = 1.54$$
$$p(w) = 0.0618$$



Свойство p-value

Утверждение.

Если при справедливости H_0

распр. статистики $T(X)$ одинаково и непрерывно,

то $p(T(X)) \sim U[0, 1]$ при H_0 .

Замечание.

Часто на практике это верно, т.к. многие критерии так и строятся.

Следствие.

Значения 0.2 и 0.9 одинаковы с точки зрения справедливости H_0 ,
т.е. p-value не есть степень уверенности в справедливости H_0 .


Что возможно, если p-value большой?

1. H_0 верна;
2. Критерий недостаточно мощный.

Общий случай p-value

$\{S_\alpha \mid \alpha \in [0, 1]\}$ — семейство критериев для разных уровней значимости.


$S_\alpha = \{T(x) > c_\alpha\}$ — критерий



Общий случай p-value

$\{S_\alpha \mid \alpha \in [0, 1]\}$ — семейство критериев для разных уровней значимости.

$S_\alpha = \{T(x) > c_\alpha\}$ — критерий




$$p\text{-value}(t) = 0.05$$

Общий случай p-value

$\{S_\alpha \mid \alpha \in [0, 1]\}$ — семейство критериев для разных уровней значимости.

$S_\alpha = \{T(x) > c_\alpha\}$ — критерий




$$p\text{-value}(t) = 0.30$$

Общий случай p-value


$\{S_\alpha \mid \alpha \in [0, 1]\}$ — семейство критериев для разных уровней значимости.

$S_\alpha = \{T(x) > c_\alpha\}$ — критерий



$$p\text{-value}(t) = 0.50$$

Общий случай p-value



$t = c_{0.5} \implies$ при $\alpha \geq 0.5$ гипотеза H_0 отвергается.

при $\alpha < 0.5$ гипотеза H_0 не отвергается.

Ключевое наблюдение: Если отвергнуть H_0 можно только совершив большую ошибку, то скорее ее не стоит отклонять.

Общий случай p-value

Вывод:

p-value — наименьший уровень значимости, при котором H_0 можно отвергнуть для данной реализации выборки x .

$$p(x) = \inf\{\alpha \in [0, 1] \mid x \in S_\alpha\}$$

Что не есть p-value

Величина p-value не является

- ▶ уровнем значимости, реальным уровнем значимости, вероятностью ошибки первого рода;
не зависят от выборки
- ▶ вероятностью H_0 , вероятностью H_0 при условии выборки;
она либо верна, либо нет
- ▶ многое еще.

Что не есть p-value (Пример)

На ЧМ по футболу в 2010 г. осьминог Пауль предсказывает результаты матчей с участием сборной Германии, выбирая кормушку с флагом страны-победителя.



$X_1, \dots, X_n \sim Bern(p)$ — результаты предсказания (правильно/нет).

$H_0: p = 1/2$ vs. $H_1: p > 1/2$ (наугад vs. не наугад)

Критерий $S = \{T(x) > c_\alpha\}$, где $T(X) = \sum X_i \sim Bin(n, p)$.

$$\text{p-value: } p(t) = \frac{1}{2^n} \sum_{j=t}^n C_n^j$$

13 матчей: Пауль верно угадывает исход матча в 11 случаях.

$$p(11) = 2^{-13} (C_{13}^{11} + C_{13}^{12} + C_{13}^{13}) \approx 0.0112 < 0.05 \implies H_0 \text{ отвергается};$$

0.0112 не является вероятностью того, что Пауль выбирает кормушку наугад

Выводы:

H_0 отвергается $\iff p\text{-value} \leq \alpha$

Если H_0 отвергается, то $p\text{-value}$ –
степень уверенности в отвержении H_0 .
(чем $p\text{-value}$ меньше, тем увереннее)

Если H_0 не отверг., то ничего сказать нельзя,
 $p\text{-value}$ не есть степень уверенности в справ. H_0 .

Если H_0 верна, то обычно $p(T(X)) \sim U[0, 1]$.

5. Проверка статистических гипотез

5.5. Практическая значимость результата

Большие выборки

$X_1, \dots, X_n \sim Bern(\theta)$ — результаты испытания Пауля.

$H_0 : \theta = 1/2$ vs. $H_1 : \theta > 1/2$

Критерий $S = \{T(x) \geq c_\alpha\}$, где $T(X) = \sum X_i \sim Bin(n, p)$.


Как критическое значение c_α зависит от n ?

Рассмотрим асимптотически эквивалентный критерий Вальда

$$W(X) = \sqrt{n} \frac{\bar{X} - 1/2}{\sqrt{1/4}} \xrightarrow{d_{1/2}} \mathcal{N}(0, 1).$$


Тогда критерий

$$S_W = \{W(x) > z_{1-\alpha}\} = \left\{ \bar{x} > \frac{1}{2} + \frac{z_{1-\alpha}}{2\sqrt{n}} \right\}.$$




Большие выборки


$$n = 10, c_\alpha = 0.9$$



$$n = 100, c_\alpha = 0.59$$



$$n = 1000, c_\alpha = 0.527$$



Вывод: при $n \rightarrow +\infty$ мощность критерия сходится к 1.

Теория: это замечательно!

Практика: не совсем...

Теория: даже при небольшом отличии истины от H_0 мы ее отклоним!

Практика: Хахаха, какой смысл в осьминоге, который угадывает с вероятностью 0.51? На сковородку его!

Вывод с точки зрения практики

Как правило, на практике:

- 1. При малом размере выборки:**

Почти ничего не отклоняется, т.к. мощность небольшая.

Недообучение

- 2. При большом размере выборки:**

Отклоняется почти все, т.к. небольшие отличия от H_0 есть почти всегда.

Переобучение

Практическая значимость

Размер эффекта — величина, оценивающая по данным, насколько основная гипотеза отличается от истины.

Пример 1.

В течении трех лет женщины выполняли физические упражнения в двух группах: группа 1 — не менее часа в день, группа 2 — не более 20 минут в день.

H_0 : изменение веса в обоих группах одинаково

H_1 : в 1 группе уменьшение веса больше, чем во 2-й

$p\text{-value} < 0.001 \implies$ результат статистически значим

Разница в весе **150 грамм** \implies результат практически не значим

Практическая значимость

Размер эффекта — величина, оценивающая по данным, насколько основная гипотеза отличается от истины.

Пример 2.

В 2002 году проводились клинические испытания гормонального препарата Премарин, которые были досрочно прерваны.

На **0.08%** увеличивается риску развития рака груди;

На **0.08%** увеличивается риск инсульта;

На **0.07%** увеличивается риск инфаркта.

С учетом численности населения есть практическая значимость.

Практическая значимость

	Есть практ. значимость	Нет практ. значимости
Есть стат. значимость	H_0 отвергается: Эффект присутствует и доказан статистически	Скорее всего в полученном результате смысла нет
Нет стат. значимости	Эффект присутствует, но не доказан статистически; нужно продолжать эксперимент	H_0 не отвергается: результата нет


План эксперимента

Как определить размер выборки **до** эксперимента?

$$X_1, \dots, X_n \sim Bern(\theta)$$

$$H_0 : \theta = 1/2 \text{ vs. } H_1 : \theta > 1/2$$

Графики мощности для критерия $S = \{\sum X_i > c_\alpha\}$:



$\alpha = 0.05$ — ур. знач.

Желаемые значения:

$\beta = 0.8$ — мощность;

$\theta \geq 0.6$ — значимый эффект.

Выбираем n , для которого
кривая мощности проходит
через точку $(0.6, 0.8)$.

5. Проверка статистических гипотез

5.6. Множественная проверка гипотез




Поиск экстрасенсов

Этап 1: Угадайте цвета (**синий** и **оранжевый**) с учетом порядка.



Поиск экстрасенсов

Этап 1: ответы.




Поиск экстрасенсов

Этап 2: Угадайте цвета (**синий** и **оранжевый**) с учетом порядка.



Поиск экстрасенсов

Этап 2: ответы.



Поиск экстрасенсов

В 1950 г. проводились испытания возможности экстрасенсорного восприятия.

Этап 1: поиск экстрасенсов — испытуемому нужно угадать цвет 10 карт.

$X_1, \dots, X_{10} \sim Bern(\theta)$ — результаты (правильно / нет).

$H_0 : \theta = 1/2$ vs. $H_1 : \theta > 1/2$ (наугад vs. не наугад)

Критерий $S = \{T(X) \geq c_\alpha\}$, где $T(X) = \sum X_i \sim Bin(n, p)$.

c	7	8	9	10
$P_{1/2}(T(X) \geq c)$	0.172	0.055	0.010	0.001

Берем $c_\alpha = 9$, т.е. H_0 отклоняется если $\sum X_i \geq 9$.

Поиск экстрасенсов

Вывод: если человек верно отгадывает хотя бы 9 карт из 10, то он становится предполагаемым экстрасенсом.

В эксперименте приняли участие 1000 человек, при этом

- ▶ 9 карт верно отгадали 9 человек;
- ▶ 10 карт верно отгадали 2 человека.



В дальнейшем ни один из них не подтвердил свои способности...

$$\begin{aligned} P_{1/2} (\text{хотя бы один из } 1000 \text{ угадает } 9 \text{ или } 10 \text{ карт верно}) &= \\ &= 1 - \left(1 - C_{10}^9 / 2^{10} - C_{10}^{10} / 2^{10}\right)^{1000} = 1 - \left(1 - 11/2^{10}\right)^{1000} \approx 0.99997 \end{aligned}$$


Материал на доске



Поиск экстрасенсов



Сравнение методов МПГ



Реализация МПГ

```
statsmodels.stats.multitest.multipletests  
(pvals, alpha=0.05, method='hs',  
is_sorted=False, returnsorted=False)
```

- ▶ pvals — значения p-value по всем критериям
- ▶ alpha — желаемый уровень значимости
- ▶ method:
 - ▶ bonferroni
 - ▶ sidak
 - ▶ fdr_bh
 - ▶ holm
 - ▶ holm-sidak
 - ▶ fdr_by

Возвращает:

- ▶ reject — для отвергаемых гипотез True
- ▶ pvals_corrected — скорректированные p-value

Простой пример

Знакомая задача:

$$X_1, \dots, X_n \sim \mathcal{N}(\theta, 1)$$

$$H_0: \theta \geq 0 \text{ vs } H_1: \theta < 0$$

$$\text{РНМК: } S = \{x \in \mathbb{R} \mid \bar{x} \leq c_\alpha\}$$

Пусть теперь две одинаковые задачи с независимыми выборками:

$$X_1, \dots, X_n \sim \mathcal{N}(\theta_1, 1)$$

$$Y_1, \dots, Y_n \sim \mathcal{N}(\theta_2, 1)$$

$$H_1: \theta_1 \geq 0 \text{ vs } H'_1: \theta_1 < 0$$

$$H_2: \theta_2 \geq 0 \text{ vs } H'_2: \theta_2 < 0$$

$$\text{Критерии: } S_1 = \{(x, y) \in \mathbb{R}^2 \mid \bar{x} \leq c_\alpha\}$$

$$S_2 = \{(x, y) \in \mathbb{R}^2 \mid \bar{y} \leq c_\alpha\}$$


Частая ошибка: Выборки независимы \implies МПГ не нужна.

Критерий S_1 Критерий S_2 Критерии S_1 и S_2 

Вывод:


вероятность допустить хотя бы одну ошибку равна 0.0975,
если обе основные гипотезы верны

Сравнение: без корректировки




Вероятности указаны при справедливости H_1 и H_2

Сравнение: метод Бонферрони




Вероятности указаны при справедливости H_1 и H_2

Сравнение: метод Холма



Вероятности указаны при справедливости H_1 и H_2


Сравнение: метод Бенджамина-Хохберга (не контр. FWER)



Вероятности указаны при справедливости H_1 и H_2

Удивительные открытия

2009 год. МРТ мозга мертвого самца лосося:



МРТ дает 3D-изображение на 130 000 вокселей.

Эксперимент: Лосося показывали фото и просили его пояснить, какие эмоции испытывают люди с картинки.

Обработка: Для каждого вокселя тестируется гипотеза о наличии активации этого участка мозга.



Удивительные открытия

Результат: Для каждой картинки для нескольких вокселей мозга p-value оказывалось меньше 0.001.

Вывод: мертвый лосось реагирует на все!!!

Авторы удостоились Шнобелевской премии (2012 год) за открытие в области неврологии.

При применении МПГ лосось переставал на что-либо реагировать...

<http://prefrontal.org/files/posters/Bennett-Salmon-2009.pdf>



Neural correlates of interspecies perspective taking in the post-mortem Atlantic Salmon: An argument for multiple comparisons correction

Craig M. Bennett¹, Abigail A. Baird², Michael B. Miller¹, and George L. Wolford³

¹ Psychology Department, University of California Santa Barbara, Santa Barbara, CA; ² Department of Psychology, Vassar College, Poughkeepsie, NY;

³ Department of Psychological & Brain Sciences, Dartmouth College, Hanover, NH

INTRODUCTION

With the extreme dimensionality of functional neuroimaging data comes extreme risk for false positives. Across the 130,000 voxels in a typical fMRI volume the probability of a false positive is almost certain. Correction for multiple comparisons should be completed with these datasets but is often

GLM RESULTS





BCE !